

Vorlesung: Numerik 1 für Ingenieure

Version 30.10.23

Michael Karow

4. Vorlesung

Thema: Matrixgeometrie und Singulärwertzerlegung

Ziel der nächsten beiden Vorlesungen:

Verständnis der Fehlerformel für lineare Gleichungssysteme.

Gegeben: Invertierbare Matrizen $A, \tilde{A} \in \mathbb{R}^{n \times n}$ und Vektoren $b, \tilde{b}, x, \tilde{x} \in \mathbb{R}^n$, $b \neq 0$, so dass

$$Ax = b, \quad \tilde{A}\tilde{x} = \tilde{b}. \quad (\text{gestörtes Gleichungssystem})$$

Dann gilt für die **relativen Fehler**,

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|\tilde{A} - A\|}{\|A\|}} \left(\frac{\|\tilde{A} - A\|}{\|A\|} + \frac{\|\tilde{b} - b\|}{\|b\|} \right)$$

sofern der Nenner > 0 ist. Dabei ist $\|x\|$ eine beliebige **Norm**,

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

die zugehörige **Matrixnorm** und

$$\text{cond}(A) = \|A\| \|A^{-1}\|. \quad (\text{Konditionszahl})$$

Eine lineare Abbildung $x \mapsto Ax$ bildet Geraden auf Geraden oder Punkte ab.

Erläuterung: Die Gerade durch den Punkt $p \in \mathbb{R}^n$ in Richtung $v \in \mathbb{R}^n, v \neq 0$, ist die Menge aller $x \in \mathbb{R}^n$ mit


$$x = p + tv, \quad t \in \mathbb{R}.$$

Multipliziert man alle x auf der Geraden mit $A \in \mathbb{R}^{m \times n}$, dann bekommt man die Menge aller


$$Ax = Ap + tAv, \quad t \in \mathbb{R}. \quad (**)$$

Dies ist die Gerade durch den Punkt Ap mit Richtungsvektor Av , es sei denn $Av = 0$. In diesem Fall ist die Bildmenge (**) nur der Punkt Ap .

Situation wenn $Av \neq 0$:



Situation wenn $Av = 0$:



Bemerkung: Der Fall $v \neq 0$ und $Av = 0$ kommt nicht vor, wenn A invertierbar ist.

Eine lineare Abbildung $x \mapsto Ax$ bildet zueinander **parallele** Geraden auf zu einander **parallele** Geraden oder Punkte ab.

Erläuterung: Zwei Geraden sind zu einander parallel, wenn sie denselben Richtungsvektor haben (oder die Richtungsvektoren Vielfache von einander sind), z.B.

$$\text{Gerade 1: } x_1 = p_1 + t v, \quad t \in \mathbb{R}.$$


$$\text{Gerade 2: } x_2 = p_2 + t v, \quad t \in \mathbb{R}.$$

Die Bildgeraden sind

$$\text{Bildgerade 1: } Ax_1 = Ap_1 + t Av, \quad t \in \mathbb{R}.$$

$$\text{Bildgerade 2: } Ax_2 = Ap_2 + t Av, \quad t \in \mathbb{R}.$$

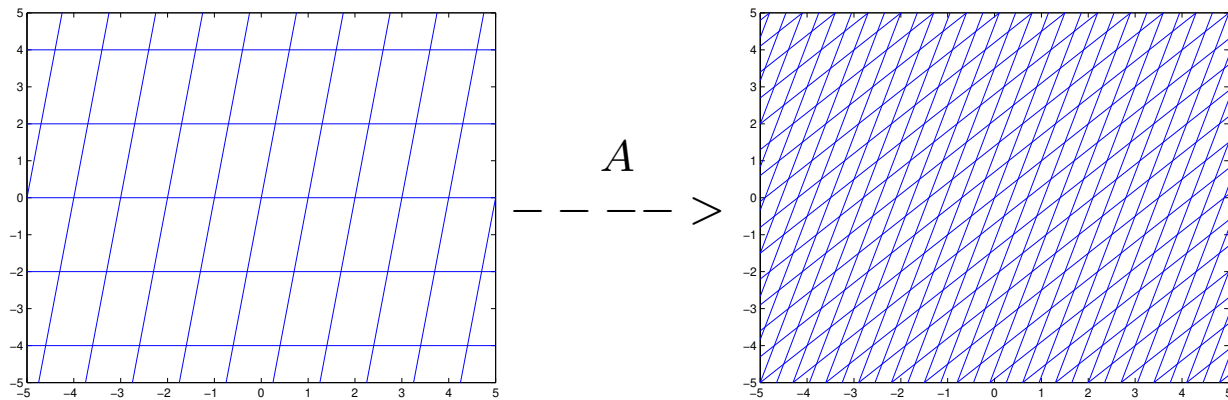
Die Richtungsvektoren der Bildgeraden sind wieder gleich. Die Bildgeraden sind also auch parallel.



Weitere Tatsache: Geht eine Gerade durch 0 , dann geht auch die Bildgerade durch 0 .

Folgerung aus den bisher genannten Tatsachen:

**Eine invertierbare lineare Abbildung $x \mapsto Ax, x \in \mathbb{R}^n$,
macht aus einem Gitter paralleler Geraden wieder ein Gitter paralleler Geraden.**



Das lineare Bild des Einheitsgitters


Das Bild des Einheitsgitters kann man direkt an der Matrix ablesen.

Es gilt nämlich: **Die Spalten von A sind die Bilder der kanonischen Basisvektoren.**

Im 2×2 Fall:

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}}_A \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix}, \quad \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix}$$

Illustration:




Linkes Bild: Einheitsgitter mit den kanonischen Basisvektoren

Rechtes Bild: Das A -Bild des Einheitsgitters mit den A -Bildern der Basisvektoren.


Die Matrix in diesem Beispiel ist $A = \begin{bmatrix} 1 & 1 \\ 0.5 & 3 \end{bmatrix}$.

Beispiel: Lineare Transformation von Figuren I

Ausgangsbild



Mit A multipliziertes Bild




In diesem Beispiel ist $A = \begin{bmatrix} 1 & -0.5 \\ -0.3 & 1 \end{bmatrix}$.


Bemerkung: Der Flächeninhalt einer beliebigen Figur multipliziert sich beim Übergang $x \mapsto Ax$ mit dem Faktor $|\det(A)|$.

Beispiel: Lineare Transformation von Figuren II

Ausgangsbild



Mit A multipliziertes Bild




In diesem Beispiel ist $A = \begin{bmatrix} -1 & 1 \\ -0.5 & 3 \end{bmatrix}$. Es ist $\det(A) < 0$.


Matrizen mit negativer Determinante bewirken eine Umkehrung der Orientierung.

Beispiel: Lineare Transformation von Figuren III

Ausgangsbild




Mit A multipliziertes Bild



In diesem Beispiel ist $A = \begin{bmatrix} \cos(\phi) & -\sin(\phi) \\ \sin(\phi) & \cos(\phi) \end{bmatrix}$, $\phi = \pi/6$.

A ist eine **Drehmatrix**.

Konstruktion von Drehmatrizen im \mathbb{R}^2



Die Bilder der kanonischen Basisvektoren bei Drehung um den Winkel ϕ gegen den Uhrzeigersinn sind

$$\begin{bmatrix} \cos(\phi) \\ \sin(\phi) \end{bmatrix}, \quad \begin{bmatrix} -\sin(\phi) \\ \cos(\phi) \end{bmatrix}.$$

In den Spalten der zugehörigen Drehmatrix stehen die Bilder der Basisvektoren.

Die Drehmatrix ist also

$$A = \begin{bmatrix} \cos(\phi) & -\sin(\phi) \\ \sin(\phi) & \cos(\phi) \end{bmatrix}.$$

Das Standard-Skalarprodukt

Das Skalarprodukt zweier Vektoren $x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$, $y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$ ist bekanntlich

$$x \cdot y = x^T y = x_1 y_1 + \dots + x_n y_n = \sum_{j=1}^n x_j y_j.$$

Euklidische Länge eines Vektors:

$$\|x\|_2 = |x| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} = \sqrt{x^T x}. \quad (1)$$


Winkel zwischen x und y :

$$\phi = \arccos \left(\frac{x^T y}{\|x\|_2 \|y\|_2} \right). \quad (2)$$

Die Gleichungen (1) und (2) sind Definitionen, die durch die Elementargeometrie motiviert sind. (1) ist der Satz des Pythagoras. (2) folgt für Vektoren aus dem Anschauungsraum aus dem [Cosinussatz](#) (siehe die nächsten Seiten).


Der Cosinussatz ist eine Verallgemeinerung des Pythagoras auf beliebige Winkel.

Pythagoras:




$$c^2 = a^2 + b^2$$

Cosinussatz:



$$c^2 = a^2 + b^2 - 2ab \cos(\phi)$$

Beweis des Satzes von Pythagoras




Bemerkung.

Alle natürlichen Zahlentripel (a, b, c) so dass $a^2 + b^2 = c^2$ können geschrieben werden als

$$a = (u^2 - v^2)^2, \quad b = (2uv)^2, \quad c = (u^2 + v^2)^2, \quad u, v = 0, 1, 2, \dots$$

Zum Beweis des Cosinussatzes (hier nur für spitze Winkel)




$$\begin{aligned}c^2 &= (a-x)^2 + h^2 & b^2 &= h^2 + x^2 \\&= (a-x)^2 + b^2 - x^2 \\&= a^2 - 2ax + x^2 + b^2 - x^2 \\&= a^2 + b^2 - 2ax\end{aligned}$$

Es ist

$$x = b \cos \phi.$$

$$\Rightarrow \quad c^2 = a^2 + b^2 - 2ab \cos \phi$$

Winkel zwischen zwei Vektoren und der Cosinussatz.



Nach dem Cosinussatz:

$$\|x - y\|_2^2 = \|x\|_2^2 + \|y\|_2^2 - 2 \|x\|_2 \|y\|_2 \cos \phi. \quad (1)$$

Mit direkter Rechnung folgt:

$$\begin{aligned} \|x - y\|_2^2 &= (x - y)^T (x - y) \\ &= (x^T - y^T)(x - y) \\ &= x^T x - x^T y - y^T x + y^T y && \text{(Es ist } x^T y = y^T x) \\ &= \|x\|_2^2 + \|y\|_2^2 - 2 x^T y \end{aligned} \quad (2)$$

Vergleich von (1) und (2) ergibt

$$\|x\|_2 \|y\|_2 \cos \phi = x^T y.$$

Also

$$\phi = \arccos \left(\frac{x^T y}{\|x\|_2 \|y\|_2} \right).$$

Senkrechte Projektion eines Vektors auf eine Achse

Sei $v \in \mathbb{R}^n$ ein Einheitsvektor ($\|v\|_2 = 1$). Sei $x \in \mathbb{R}^n$ beliebig.

Gesucht ist die senkrechte Projektion Px von x auf die Gerade $\mathbb{R}v$. Genauer formuliert:


Es ist $Px = \lambda v = v\lambda$ mit $\lambda \in \mathbb{R}$ so dass $x - Px = x - v\lambda$ senkrecht auf v steht, also

$$0 = v^\top (x - Px) = v^\top (x - v\lambda) = v^\top x - \underbrace{v^\top v}_{=1} \lambda \quad \Rightarrow \quad \lambda = v^\top x.$$

Folglich:

$$Px = v(v^\top x) = (vv^\top)x = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} v_1^2 & v_1 v_2 & \cdots & v_1 v_n \\ v_2 v_1 & v_2^2 & \cdots & v_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ v_n v_1 & v_n v_2 & \cdots & v_n^2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$


Ansatz:



$$\lambda = v^\top x$$

----->

Lösung:



Senkrechte Projektion eines Vektors auf eine Achse

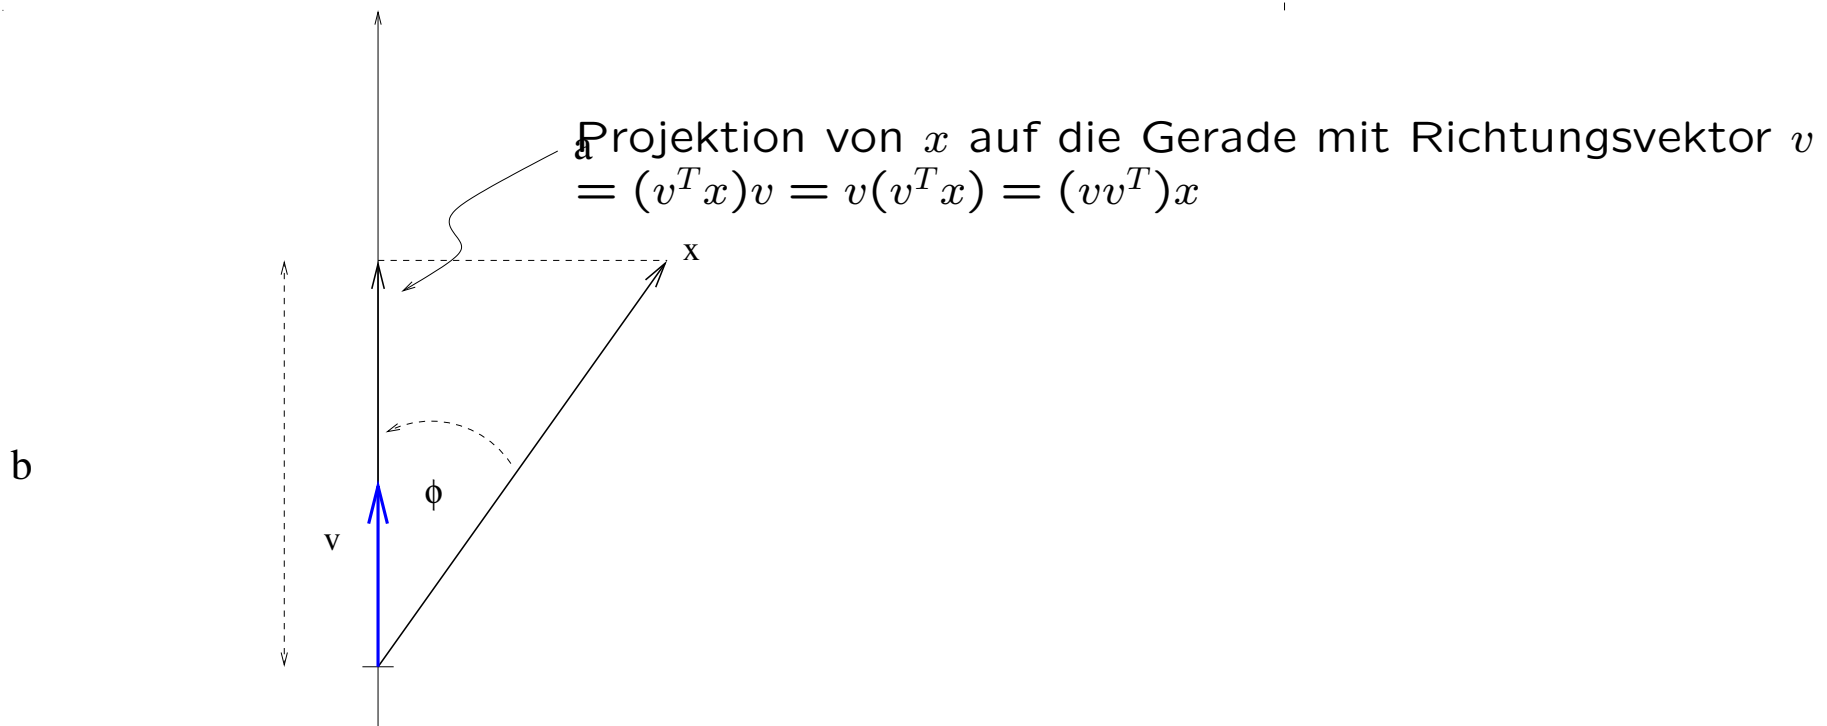
Erinnerung: Für den Winkel ϕ zwischen 2 Vektoren x, v gilt $\cos \phi = \frac{v^T x}{\|v\|_2 \|x\|_2}$.

Wenn v die Länge 1 hat, dann folgt $v^T x = \|x\|_2 \cos \phi$.

Die senkrechte Projektion von x auf die Gerade durch 0 mit Richtungsvektor v ist dann

$$x \longmapsto (v^T x) v = v (v^T x) = (v v^T) x.$$


Folgerung: Die Projektion ist eine (nicht invertierbare) lineare Abbildung $x \mapsto Ax$ mit der Matrix $A = v v^T$.



Spiegelung an einer (Hyper)ebene

Sei $v \in \mathbb{R}^n$ ein Einheitsvektor (d.h. $\|v\|_2 = 1$).

Wenn man von einem Vektor x das doppelte der senkrechten Projektion von x auf die Gerade durch v abzieht, dann hat man x dadurch an der (Hyper)ebene senkrecht zu v gespiegelt.



Dies ist wieder eine lineare Abbildung: $x \mapsto x - 2vv^T x = \underbrace{(I - 2vv^T)}_A x.$

Die Spiegelungsmatrix A nennt man auch **Householdermatrix**.

Solche Matrizen sind in der Numerik sehr wichtig. Dazu später mehr.

Spiegelungen in \mathbb{R}^2

Wir haben gesehen, dass

die Matrizen $R_t = \begin{bmatrix} \cos(t) & -\sin(t) \\ \sin(t) & \cos(t) \end{bmatrix}$ Drehmatrizen sind.

Wir zeigen, dass

die Matrizen $\tilde{R}_t = \begin{bmatrix} \cos(t) & \sin(t) \\ \sin(t) & -\cos(t) \end{bmatrix}$ Spiegelungsmatrizen sind.

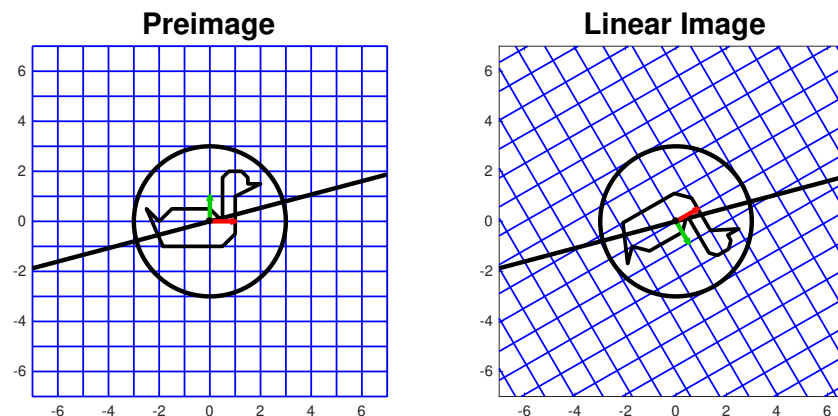
Beweis. Sei $c = \cos(t/2)$, $s = \sin(t/2)$.

Wegen der Additionstheoreme für sin und cos und Pythagoras ($c^2 + s^2 = 1$) hat man,

$$\underbrace{\begin{bmatrix} c^2 - s^2 & 2sc \\ 2sc & s^2 - c^2 \end{bmatrix}}_{\tilde{R}_t} \underbrace{\begin{bmatrix} c \\ s \end{bmatrix}}_u = \underbrace{\begin{bmatrix} c \\ s \end{bmatrix}}_u, \quad \underbrace{\begin{bmatrix} c^2 - s^2 & 2sc \\ 2sc & s^2 - c^2 \end{bmatrix}}_{\tilde{R}_t} \underbrace{\begin{bmatrix} -s \\ c \end{bmatrix}}_v = - \underbrace{\begin{bmatrix} -s \\ c \end{bmatrix}}_v.$$

Folgerung: Multiplikation mit \tilde{R}_t läßt alle Vektoren der gerade $\mathbb{R}u$ fest und multipliziert alle Vektoren auf $\mathbb{R}v$ mit -1. Man rechnet leicht nach, dass $\tilde{R}_t = I - 2vv^\top$.


Beispiel: \tilde{R} for $t = \pi/6$:



Drehungen (Rotationen) im \mathbb{R}^3 , I

Alle Drehungen im \mathbb{R}^3 sind Produkte (Hinereinanderausführung) von Drehungen um x, y und z -Achse. Die Drehmatrix $A \in \mathbb{R}^{3,3}$ ist

$$A = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos(\alpha) & -\sin(\alpha) \\ 0 & \sin(\alpha) & \cos(\alpha) \end{bmatrix}}_{\substack{\text{Rot. um } x\text{-Achse} \\ \text{Wanken} \\ (\text{eng.: roll})}} \underbrace{\begin{bmatrix} \cos(\beta) & 0 & -\sin(\beta) \\ 0 & 1 & 0 \\ \sin(\beta) & 0 & \cos(\beta) \end{bmatrix}}_{\substack{\text{Rot. um } y\text{-Achse} \\ \text{Nicken} \\ (\text{engl.: pitch})}} \underbrace{\begin{bmatrix} \cos(\gamma) & -\sin(\gamma) & 0 \\ \sin(\gamma) & \cos(\gamma) & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\substack{\text{Rot. um } z\text{-Achse} \\ \text{Gieren} \\ (\text{engl.: yaw})}}$$



Dies ist die **Tait-Bryan-Darstellung** einer Drehung.

Euler verwendete drei Drehungen um nur zwei Achsen:

$$A = \underbrace{\begin{bmatrix} \cos(\phi) & -\sin(\phi) & 0 \\ \sin(\phi) & \cos(\phi) & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\text{Rot. um } z\text{-Achse}} \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos(\psi) & -\sin(\psi) \\ 0 & \sin(\psi) & \cos(\psi) \end{bmatrix}}_{\text{Rot. um } x\text{-Achse}} \underbrace{\begin{bmatrix} \cos(\theta) & -\sin(\theta) & 0 \\ \sin(\theta) & \cos(\theta) & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\text{Rot. um } z\text{-Achse}}$$

Bem.: Die Matrizen kommutieren nicht. Änderung der Reihenfolge ändert die Drehung.

Alle Drehungen in \mathbb{R}^3 können aber auch als Drehung um eine einzige Achse dargestellt werden. Siehe nächste Seite.

Das Bild oben ist von Georg Eckert (Wikipedia).

Drehungen im \mathbb{R}^3 , II

Sei $v \in \mathbb{R}^3$ ein Einheitsvektor, d.h. $\|v\|_2 = 1$. Die Drehung im \mathbb{R}^3 um die Achse mit Richtungsvektor v und um den Winkel ϕ ist folgende lineare Abbildung:


$$x \mapsto Ax = 2 \begin{bmatrix} p_0^2 + p_1^2 - \frac{1}{2} & p_1 p_2 - p_0 p_3 & p_1 p_3 + p_0 p_2 \\ p_1 p_2 + p_0 p_3 & p_0^2 + p_2^2 - \frac{1}{2} & p_2 p_3 - p_0 p_1 \\ p_1 p_3 - p_0 p_2 & p_2 p_3 + p_0 p_1 & p_0^2 + p_3^2 - \frac{1}{2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

wobei

$$p_0 = \cos(\phi), \quad \begin{bmatrix} p_1 \\ p_2 \\ p_3 \end{bmatrix} = \sin(\phi) v.$$

Bemerkung: Es ist

$$\left\| \begin{bmatrix} p_0 \\ p_1 \\ p_2 \\ p_3 \end{bmatrix} \right\|_2 = 1.$$




D.h. der p -Vektor ist ein Einheitsvektor im 4-dimensionalen Raum.

Drehungen im \mathbb{R}^3 , II

Sei $v \in \mathbb{R}^3$ mit $\|v\|_2 = 1$.

Die Drehung im \mathbb{R}^3 um die Achse mit Richtungsvektor v und um den Winkel ϕ ist die unten angegebene lineare Abbildung $x \mapsto Ax$.

Grund: Die orthogonale Projektion $vv^\top x$ von x auf die Drehachse bleibt bei der Drehung unverändert. Die beiden Vektoren $x - vv^\top x$ und $v \times x$ sind orthogonal zueinander, gleich lang und spannen die Ebene senkrecht zur Drehachse auf.



$$\begin{aligned}
 Ax &= vv^\top x + \overbrace{\cos(\phi) (x - vv^\top x) + \sin(\phi) v \times x}^{\text{Drehung in der Ebene}} \\
 &= \underbrace{\begin{bmatrix} (1 - c) v_1^2 + c & (1 - c) v_1 v_2 - s v_3 & (1 - c) v_1 v_3 + s v_2 \\ (1 - c) v_2 v_1 + s v_3 & (1 - c) v_2^2 + c & (1 - c) v_2 v_3 - s v_1 \\ (1 - c) v_3 v_1 - s v_2 & (1 - c) v_3 v_2 + s v_1 & (1 - c) v_3^2 + c \end{bmatrix}}_{\text{Drehmatrix}} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}
 \end{aligned}$$

Drehungen im \mathbb{R}^3 , III

Drehmatrix von der vorherigen Seite:

$$A = \begin{bmatrix} (1 - c) v_1^2 + c & (1 - c) v_1 v_2 - s v_3 & (1 - c) v_1 v_3 + s v_2 \\ (1 - c) v_2 v_1 + s v_3 & (1 - c) v_2^2 + c & (1 - c) v_2 v_3 - s v_1 \\ (1 - c) v_3 v_1 - s v_2 & (1 - c) v_3 v_2 + s v_1 & (1 - c) v_3^2 + c \end{bmatrix}, \quad \text{wobei} \quad \begin{array}{l} c = \cos(\phi), \\ s = \sin(\phi). \end{array}$$

Eine andere Darstellung der Drehmatrix bekommt man mit den trigonometrischen Identitäten

$$\cos(\phi) = 1 - 2 \sin^2(\phi/2), \quad \sin(\phi) = 2 \sin(\phi/2) \cos(\phi/2)$$

und den Definitionen

$$q_0 := \cos(\phi/2), \quad q_k := \sin(\phi/2) v_k, \quad k = 1, 2, 3.$$

Es ist

$$q_0^2 + q_1^2 + q_2^2 + q_3^2 = v_1^2 + v_2^2 + v_3^2 = 1$$

und

$$\begin{aligned} A &= \begin{bmatrix} 1 - 2(q_2^2 + q_3^2) & 2(q_1 q_2 - q_0 q_3) & 2(q_1 q_3 + q_2 q_0) \\ 2(q_2 q_1 + q_0 q_3) & 1 - 2(q_1^2 + q_3^2) & 2(q_2 q_3 - q_1 q_0) \\ 2(q_3 q_1 - q_2 q_0) & 2(q_3 q_2 + q_1 q_0) & 1 - 2(q_1^2 + q_2^2) \end{bmatrix} \\ &= \begin{bmatrix} -q_1 & q_0 & -q_3 & q_2 \\ -q_2 & q_3 & q_0 & -q_1 \\ -q_3 & -q_2 & q_1 & q_0 \end{bmatrix} \begin{bmatrix} -q_1 & -q_2 & -q_3 \\ q_0 & -q_3 & q_2 \\ q_3 & q_0 & -q_1 \\ -q_2 & q_1 & q_0 \end{bmatrix} \end{aligned}$$

Drehungen und Spiegelungen sind längen- und winkelerhaltend.

Solche linearen Abbildungen nennt man **orthogonale Transformationen**.

Die zugehörigen Matrizen heißen **orthogonale Matrizen**.

Orthogonale Matrizen

Satz: Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

1. $\|Ax\|_2 = \|x\|_2$ für alle $x \in \mathbb{R}^n$.
2. $(Ax)^T(Ay) = x^T y$ für alle $x, y \in \mathbb{R}^n$.
3. $A^T A = I$ (I = Einheitsmatrix)
4. $A^T = A^{-1}$.
5. Die Spalten von A stehen senkrecht aufeinander und haben alle die Länge 1.
Sie bilden also eine **Orthonormalbasis** von \mathbb{R}^n . Formal:

$$A = [a_1 \ a_2 \ \dots \ a_n] \quad \Rightarrow \quad a_j^T a_k = \delta_{jk} = \begin{cases} 1 & \text{falls } k = j \\ 0 & \text{sonst} \end{cases}$$

6. Die Zeilen von A stehen senkrecht aufeinander und haben die Länge 1.
7. $AA^T = I$.

Wenn eine dieser Bedingungen erfüllt ist, dann sind auch alle anderen Bedingungen erfüllt. In diesem Fall nennt man die Matrix A **orthogonal**.

Für orthogonale Matrizen gilt stets $1 = \det(I) = \det(A^T A) = \det(A^T) \det(A) = \det(A)^2$, also

$$\det(A) = 1 \quad \text{oder} \quad \det(A) = -1.$$

Gramsche Matrizen

Sei $A = [a_1 \ a_2 \ \dots \ a_n] \in \mathbb{R}^{m \times n}$ eine beliebige Matrix mit Spalten a_k . Dann gilt

$$A^T A = \begin{bmatrix} a_1^T a_1 & a_1^T a_2 & \dots & a_1^T a_n \\ a_2^T a_1 & a_2^T a_2 & \dots & a_2^T a_n \\ \vdots & & & \vdots \\ a_n^T a_1 & a_n^T a_2 & \dots & a_n^T a_n \end{bmatrix}.$$

Die symmetrische Matrix $A^T A$ enthält also sämtliche Skalarprodukte der Spalten von A .

Insbesondere gilt

$$A^T A = I \quad (I = \text{Einheitsmatrix}) \quad \Leftrightarrow \quad \begin{array}{l} \text{Die Spalten von } A \text{ sind senkrecht} \\ \text{zueinander und haben Länge 1} \end{array}.$$

Definition: $A^T A$ heißt **Gramsche Matrix** von A .

Jørgen Pedersen Gram (1850-1916), Dänischer Versicherungsmathematiker.

Erinnerung an die Lineare-Algebra-Vorlesung

Seien v_1, v_2, \dots, v_p Eigenvektoren von $A \in \mathbb{C}^{n \times n}$, so dass

$$Av_k = \lambda_k v_k, \quad \lambda_k \in \mathbb{C}, \quad k = 1, \dots, p. \quad (*)$$

Dann gilt

$$AV = V\Lambda, \quad (**)$$

wobei

$$V = [v_1 \ v_2 \ \dots \ v_p], \quad \Lambda = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{bmatrix}.$$

Umgekehrt folgt auch (*) aus (**) (siehe unten).

Wenn $p = n$ und die Eigenvektoren linear unabhängig sind, also eine Basis des \mathbb{C}^n bilden, dann ist die Matrix V invertierbar und aus (**) folgt

$$A = V\Lambda V^{-1}. \quad (***)$$

Diese Produktdarstellung nennt man eine **Diagonalisierung** von A .

Nicht jede Matrix besitzt eine Basis von Eigenvektoren (Stichwort: Hauptvektoren, Jordansche Normalform).

Herleitung von () aus (*):** Durch direktes Nachrechnen zeigt man

$$A[v_1 \ v_2 \ \dots \ v_p] = [Av_1 \ Av_2 \ \dots \ Av_p] = [\lambda_1 v_1 \ \lambda_2 v_2 \ \dots \ \lambda_p v_p] = [v_1 \ v_2 \ \dots \ v_p] \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \end{bmatrix}.$$

Im allgemeinen können bei einer Matrix $A \in \mathbb{R}^{n \times n}$ die folgenden Fälle auftreten:

- Die Matrix A besitzt keine Basis von Eigenvektoren.

Beispiel: Es ist

$$\underbrace{\begin{bmatrix} \lambda & 1 & & & \\ & \lambda & 1 & & \\ & & \ddots & \ddots & \\ & & & \ddots & 1 \\ & & & & \lambda \end{bmatrix}}_J \underbrace{\begin{bmatrix} \alpha \\ 0 \\ \vdots \\ \vdots \\ 0 \end{bmatrix}}_v = \lambda \begin{bmatrix} \alpha \\ 0 \\ \vdots \\ \vdots \\ 0 \end{bmatrix}, \quad \alpha \in \mathbb{C}$$

Man kann zeigen, dass die Jordanmatrix J außer den Vektoren v keine weiteren Eigenvektoren hat. Es gibt also keine Basis von Eigenvektoren.

- Die Eigenwerte und -Vektoren können komplex sein.

Beispiel Drehmatrizen:

$$\begin{bmatrix} \cos(\phi) & -\sin(\phi) \\ \sin(\phi) & \cos(\phi) \end{bmatrix} \begin{bmatrix} 1 \\ \pm i \end{bmatrix} = e^{\mp i\phi} \begin{bmatrix} 1 \\ \pm i \end{bmatrix}.$$

- Die Eigenvektoren können in jedem beliebigen, insbesondere auch sehr spitzem Winkel zueinander stehen.

Beispiel:

$$\begin{bmatrix} 1 & x^2 - 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \pm 1 \\ \pm 1 \end{bmatrix} = (\pm x) \begin{bmatrix} x \pm 1 \\ \pm 1 \end{bmatrix}$$

Für den Cosinus des Winkels ϕ_x zwischen den Eigenvektoren (Skalarprodukt durch Produkt der Längen) hat man $\lim_{x \rightarrow \infty} \cos(\phi_x) = 1$. Der Winkel zwischen den Eigenvektoren konvergiert also gegen 0.

Satz von der Hauptachsentransformation einer symmetrischen Matrix (Spektralsatz):

Sei $A \in \mathbb{R}^{n \times n}$ eine **symmetrische** Matrix. Dann gibt es eine Diagonalmatrix $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ und eine orthogonale Matrix $V = [v_1, \dots, v_n] \in \mathbb{R}^{n \times n}$, so dass

$$A = V \Lambda V^T.$$

Die Spalten von V bilden eine Orthonormalbasis von Eigenvektoren von A zu den Eigenwerten λ_k . Genauer gilt:

$$Av_k = \lambda_k v_k, \quad \text{und} \quad v_j^T v_k = \delta_{jk} = \begin{cases} 1 & \text{falls } j = k \\ 0 & \text{sonst} \end{cases}$$

Bemerkung:

In (*) kann man statt V^T auch V^{-1} schreiben, denn weil V orthogonal ist, gilt $V^T = V^{-1}$.

Der Rayleigh-Quotient

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch. Laut dem Satz von der Hauptachsentransformation gibt es eine orthonormale Eigenvektorbasis $v_1, v_2, \dots, v_n \in \mathbb{R}^n$,

$$Av_j = \lambda_j v_j, \quad \lambda_k \in \mathbb{R}, \quad v_j^T v_k = \begin{cases} 1 & \text{if } j = k \\ 0 & \text{otherwise} \end{cases}$$

Jeder Vektor $x \in \mathbb{R}^n$ kann geschrieben werden als Linearkombination von Eigenvektoren:

$$x = x_1 v_1 + x_2 v_2 + \dots + x_n v_n, \quad x_j \in \mathbb{R}.$$

Direkte Rechnung ergibt:


$$\begin{aligned} x^T A x &= (x_1 v_1 + x_2 v_2 + \dots + x_n v_n)^T A (x_1 v_1 + x_2 v_2 + \dots + x_n v_n) \\ &= (x_1 v_1 + x_2 v_2 + \dots + x_n v_n)^T (x_1 \lambda_1 v_1 + x_2 \lambda_2 v_2 + \dots + x_n \lambda_n v_n) \\ &= \lambda_1 x_1^2 \underbrace{v_1^T v_1}_{=1} + \lambda_2 x_1 x_2 \underbrace{v_1^T v_2}_{=0} + \dots + \lambda_2 x_2^2 \underbrace{v_2^T v_2}_{=1} + \dots \\ &= \lambda_1 x_1^2 + \lambda_2 x_2^2 + \dots + \lambda_n x_n^2 \end{aligned}$$

Wir definieren den **Rayleigh-Quotient** von x als

$$R(x) := \frac{x^T A x}{\|x\|_2^2} = \frac{\lambda_1 x_1^2 + \lambda_2 x_2^2 + \dots + \lambda_n x_n^2}{x_1^2 + x_2^2 + \dots + x_n^2} \begin{cases} \leq \lambda_1 & \text{wenn } \lambda_1 \text{ gr\u00f6\u00dfter Eigenwert} \\ \geq \lambda_n & \text{wenn } \lambda_n \text{ kleinster Eigenwert} \end{cases}$$

Extrema werden angenommen bei $x = v_1$ bzw. $x = v_n$.

Rayleigh-Quotient: Anschauung



Das Bild zeigt die Niveau-Mengen des Rayleigh-Quotienten

$$R(v) = \frac{v^\top A v}{\|v\|_2^2}, \quad A = \text{diag}\{1, 2, 3\},$$

auf der Einheitssphäre im \mathbb{R}^3 .

Das Bild zeigt auch die Eigenräume von A

Das Eigenwertkriterium für positive Definitheit

Satz: Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch. Dann gilt:

A ist genau dann **positiv definit**, wenn alle Eigenwerte von A positiv sind.

Beweis des Eigenwertkriteriums: Nach dem Spektralsatz existiert eine Orthonormalbasis $v_1, v_2, \dots, v_n \in \mathbb{R}^n$ von Eigenvektoren:

$$Av_j = \lambda_j v_j, \quad v_j^T v_k = \begin{cases} 1 & \text{falls } j = k \\ 0 & \text{sonst} \end{cases}$$

Jeder Vektor $x \in \mathbb{R}^n$ lässt sich dann als Linearkombination der Eigenvektoren schreiben:

$$x = x_1 v_1 + x_2 v_2 + \dots + x_n v_n, \quad x_j \in \mathbb{R}.$$

Eine direkte Rechnung ergibt:

$$\begin{aligned} x^T A x &= (x_1 v_1 + x_2 v_2 + \dots + x_n v_n)^T A (x_1 v_1 + x_2 v_2 + \dots + x_n v_n) \\ &= (x_1 v_1 + x_2 v_2 + \dots + x_n v_n)^T (x_1 \lambda_1 v_1 + x_2 \lambda_2 v_2 + \dots + x_n \lambda_n v_n) \\ &= \lambda_1 x_1^2 \underbrace{v_1^T v_1}_{=1} + \lambda_2 x_1 x_2 \underbrace{v_1^T v_2}_{=0} + \dots + \lambda_2 x_2^2 \underbrace{v_2^T v_2}_{=1} + \dots \\ &= \lambda_1 x_1^2 + \lambda_2 x_2^2 + \dots + \lambda_n x_n^2 \end{aligned}$$

Wenn alle Eigenwerte positiv sind, folgt $x^T A x > 0$ für alle $x \neq 0$.

Wenn ein Eigenwert λ_k negativ ist, dann folgt $v_k^T A v_k = \lambda_k < 0$.

Gramsche Matrizen sind positiv semidefinit

Sei $A \in \mathbb{R}^{m \times n}$ eine beliebige reelle Matrix. Dann ist für alle $x \in \mathbb{R}^n$,

$$x^T A^T A x = (Ax)^T (Ax) = \|Ax\|_2^2 \geq 0.$$

\Rightarrow $A^T A$ ist positiv semidefinit und hat daher keine negativen Eigenwerte.

Wenn A linear unabhängige Spalten hat, dann ist $Ax = 0$ nur für $x = 0$.

Also ist $x^T A^T A x = 0$ nur für $x = 0$.

Also ist $A^T A$ positiv definit und hat daher nur positive Eigenwerte.

Rayleigh-Quotient einer Gramschen Matrix, Streckfaktor und Spektralnorm

Sei $A \in \mathbb{R}^{m \times n}$ (muss nicht quadratisch sein).

Der Quotient $\|Ax\|_2/\|x\|_2$ ist der **Streckfaktor** von x bei Multiplikation mit A .

Der **maximale Streckfaktor** heißt **Spektralnorm** von A ,

$$\|A\|_2 := \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

Das Quadrat des Streckfaktors ist ein Rayleigh-Quotient:

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} = \frac{(Ax)^T(Ax)}{\|x\|_2^2} = \frac{x^T A^T A x}{\|x\|_2^2} = \frac{\lambda_1 x_1^2 + \lambda_2 x_2^2 + \dots + \lambda_n x_n^2}{x_1^2 + x_2^2 + \dots + x_n^2}$$

Dabei ist

$$x = x_1 v_1 + x_2 v_2 + \dots + x_n v_n, \quad x_j \in \mathbb{R}$$

dargestellt als eine Linearkombination der Eigenvektoren von $A^T A$ mit zugehörigen Eigenwerten $\lambda_k = \lambda_k(A^T A)$. Es folgt, dass

$$\sqrt{\lambda_{\min}(A^T A)} \leq \frac{\|Ax\|_2}{\|x\|_2} \leq \sqrt{\lambda_{\max}(A^T A)} = \|A\|_2$$

Übungsaufgabe: Zeige, dass für invertierbares A ,

$$\sqrt{\lambda_{\min}(A^T A)} = \|A^{-1}\|_2^{-1}.$$

Definition. Die Quadratwurzeln $\sigma_k := \sqrt{\lambda_k(A^T A)}$ heißen **Singulärwerte** von A .

Singulärwertzerlegung (hier nur für quadratische Matrizen)

Den **Satz von der Singulärwertzerlegung** (singular value decomposition, kurz: **SVD**) kann man auf 2 verschiedene Weisen formulieren:

Sei $A \in \mathbb{R}^{n \times n}$ eine beliebige Matrix.

Formulierung 1: Es gibt Orthonormalbasen $u_1, u_2, \dots, u_n \in \mathbb{R}^n$ und $v_1, v_2, \dots, v_n \in \mathbb{R}^n$ und nicht negative Zahlen $\sigma_1, \sigma_2, \dots, \sigma_n \in \mathbb{R}$, so dass gilt

$$Av_k = \sigma_k u_k, \quad k = 1, \dots, n \quad (*)$$

Terminologie: Die Vektoren u_k, v_k heißen **singuläre Vektoren**.

Die Zahlen σ_k heißen **Singulärwerte**.

Formulierung 2: Es gibt orthogonale Matrizen $U, V \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix Σ mit nicht negativen Diagonalelementen, so dass

$$A = U \Sigma V^T. \quad (**)$$

Zusammenhang zwischen beiden Formulierungen: $(*) \Rightarrow$

$$A \underbrace{[v_1 \ v_2 \ \dots \ v_n]}_V = [Av_1 \ Av_2 \ \dots \ Av_n] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_n u_n] = \underbrace{[u_1 \ u_2 \ \dots \ u_n]}_U \underbrace{\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}}_{\Sigma}.$$

D.h.: $AV = U\Sigma$. Multiplikation mit $V^T = V^{-1}$ ergibt: $A = U\Sigma V^T$.



Anschauung zu Formulierung 1 des Satzes von der Singulärwertzerlegung.

Die Matrix $A \in \mathbb{R}^{2 \times 2}$ im Beispiel unten hat die Singulärwerte

$$\sigma_1 = 2, \quad \sigma_2 = 1/2.$$

Die singulären Vektoren von A sind v_1, v_2 und u_1, u_2 . Sie bilden Orthonormalbasen. Es gilt

$$Av_1 = \sigma_1 u_1, \quad Av_2 = \sigma_2 u_2.$$



Deutung der Singulärwertzerlegung $A = U\Sigma V^T$:

Jede lineare Abbildung $x \mapsto Ax$ ist eine Hintereinanderausführung

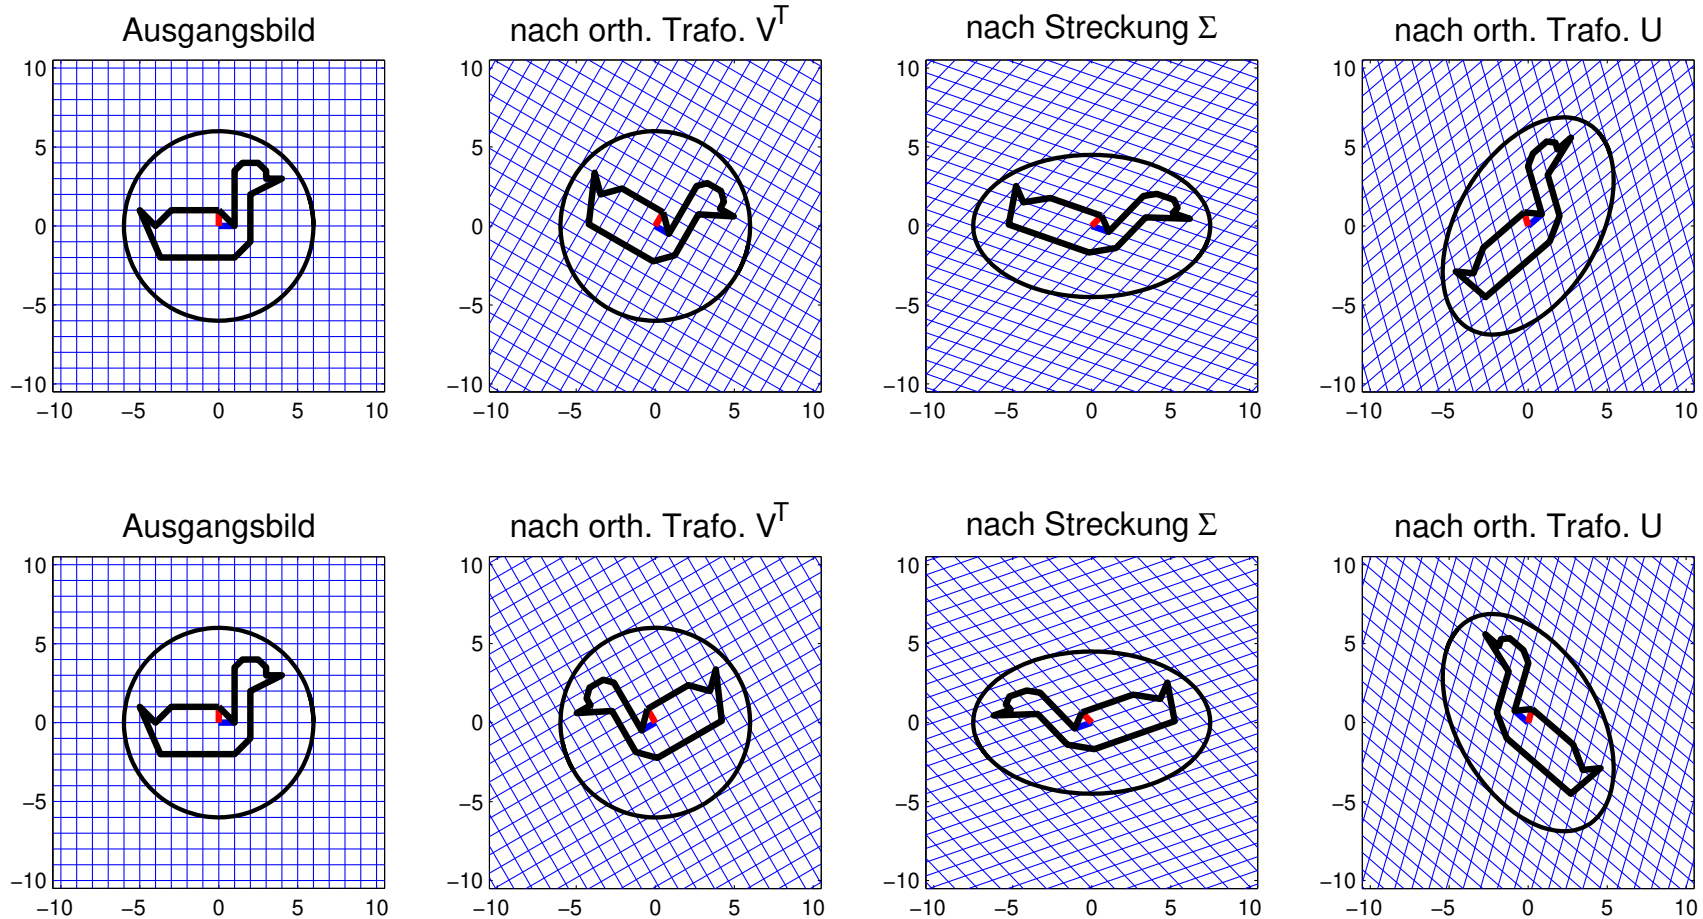
- einer orthogonalen (d.h. längen- und winkelerhaltenden) Abbildung V^T ,
- Einer Streckung/Stauchung Σ entlang der Achsen des Standard-Koordinatensystems,
- einer orthogonalen (d.h. längen- und winkelerhaltenden) Abbildung U .

$$x \xrightarrow{V^T} V^T x \xrightarrow{\Sigma} \Sigma V^T x \xrightarrow{U} U \Sigma V^T x = Ax$$

Siehe die Beispiele auf der nächsten Seite.

Beispiel zur Singulärwertzerlegung, Formulierung 2

Singulärwertzerlegung: $A = U \Sigma V^T$ mit $U^T U = I$, $V^T V = I$, $\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}$.



Bilder: die Trafos V^T, Σ, U für $A = \begin{bmatrix} 0.87 & -0.25 \\ 0.75 & 0.87 \end{bmatrix}$ (oben) und $A = \begin{bmatrix} -0.87 & 0.25 \\ 0.75 & 0.87 \end{bmatrix}$ (unten).

In beiden Fällen ist $\sigma_1(A) \approx 1.25$, $\sigma_2(A) \approx 0.75$.

Folgerungen aus der Singulärwertzerlegung

Sei $A = U\Sigma V^T$ eine Singulärwertzerlegung von A .

Dann ist

$A^T = V\Sigma U^T$ eine Singulärwertzerlegung von A^T ,

$A^{-1} = V\Sigma^{-1}U^T$ eine Singulärwertzerlegung von A^{-1} (falls A^{-1} existiert)

Außerdem folgt

$$A^T A = (V \underbrace{\Sigma U^T U}_{I} \Sigma V^T) = V \Sigma^2 V^T, \quad (*)$$

$$A A^T = (U \underbrace{\Sigma V^T V}_{I} \Sigma U^T) = U \Sigma^2 U^T. \quad (**)$$

Dies sind Diagonalisierungen der symmetrischen und positiv (semi)definiten Matrizen $A^T A$, $A A^T$. Somit sind die Einträge von

$$\Sigma^2 = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)$$

die Eigenwerte von $A^T A$ und $A A^T$. Anders formuliert:

Die Singulärwerte von A sind die Wurzeln aus den Eigenwerten von $A^T A$ und von $A A^T$,

$$\sigma_k(A) = \sqrt{\lambda_k(A^T A)} = \sqrt{\lambda_k(A A^T)}.$$

Aus (*) und (**) folgt weiter:

Die singulären Vektoren V sind die Eigenvektoren von $A^T A$, die singulären Vektoren U sind die Eigenvektoren von $A A^T$.

Berechnung der Singulärwertzerlegung einer invertierbaren Matrix

Aus den Folgerungen auf der vorigen Seite ergibt sich folgendes Verfahren zur Berechnung einer Singulärwertzerlegung einer invertierbaren Matrix.

- Berechne eine Orthonormalbasis $V = [v_1 \ v_2 \ \dots \ v_n]$ von Eigenvektoren von $A^T A$, so dass $A^T A v_k = \lambda_k v_k$.
- Die Eigenwerte λ_k der positiv definiten symmetrischen Matrix $A^T A$ sind positiv. Setze $\sigma_k := \sqrt{\lambda_k}$. Dann ist

$$(Av_j)^T(Av_k) = v_j^T A^T A v_k = v_j^T(\sigma_k^2 v_k) = \sigma_k^2 v_j^T v_k = \sigma_k^2 \delta_{jk}, \quad (*)$$

Insbesondere $\|Av_k\|_2 = \sqrt{(Av_k)^T(Av_k)} = \sigma_k$.

- Setze $u_k := Av_k/\sigma_k$ und bilde $U = [u_1 \ u_2 \ \dots \ u_n]$. Dann gilt

$$Av_k = \sigma_k u_k \quad (**)$$

und aus (*) folgt, dass die u_k eine Orthonormalbasis bilden.

Wegen (**) hat man $AV = U\Sigma$ mit $\Sigma := \text{diag}(\sigma_1, \dots, \sigma_n)$, also auch

$$A = U\Sigma V^T.$$

Singulärwertzerlegung (singular value decomposition) mit Matlab

$s = \text{svd}(A)$ gibt einen Vektor s zurück, in dem die Singulärwerte von A stehen.

$[U, S, V] = \text{svd}(A)$ gibt die volle Singulärwertzerlegung zurück: $A = USV^T$.

Bei symmetrischen Matrizen sind Diagonalisierung und Singulärwertzerlegung bis aufs Vorzeichen dasselbe

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch und sei

$$A = V \Lambda V^T, \quad V^T V = I, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

eine orthogonale Diagonalisierung. Sei

$$\Sigma = |\Lambda| = \text{diag}(|\lambda_1|, \dots, |\lambda_n|), \quad D = \text{diag}(\text{sign}(\lambda_1), \dots, \text{sign}(\lambda_n)),$$

wobei $\text{sign}(\cdot) = \text{Vorzeichen}$. Dann ist $\Lambda = D \Sigma$ und

$$A = \underbrace{VD}_{=:U} \Sigma V^T. \quad (*)$$

U ist orthogonal: $U^T U = (VD)^T (VD) = \underbrace{D^T}_{=D} \underbrace{V^T V}_{=I} D = D^2 = I$.

Daher ist $(*)$ eine Singulärwertzerlegung.

Wenn A positiv definit ist, dann ist $D = I$ und $\Lambda = \Sigma$.

\Rightarrow Bei positiv definiten sym. Matrizen sind die Eigenwerte die Singulärwerte.

Singulärwertzerlegung und Konditionszahlen

Aus der Singulärwertzerlegung lässt sich leicht herleiten, dass

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

Genaueres in der nächsten Vorlesung.